INTELIGÊNCIA ARTIFICIAL NA SAÚDE

Tecnologia para ampliar a eficiência sem perder o humano



A pergunta não é se a IA vai chegar. Ela já chegou.

ERClinic.com.br

O que me trouxe até aqui

Robertson Ebling dos Santos

Bacharel em Sistemas de Informação – UFN
Santa Maria – RS

Computação
há **27 anos**

Desenvolvimento de software / Saúde
há **18 anos**



Tecnologia como meio para gerar valor na saúde

Soluções que conectam gestão, profissionais e pacientes

Inovação aplicada à realidade dos consultórios e clínicas



Elizandro Ilha
Bacharel SI

ER Clinic



Robertson
Bacharel SI

Healthtech santamariense



Há 11 anos ajudamos clínicas e consultórios a gerirem melhor seus processos e pacientes por meio de um software Web em modelo de assinatura mensal (SaaS).

TREINO SCOUT

Transformamos dados em resultados para elevar o desempenho de atletas.



Torneios de Integração



IA

- Inferência para identificação de categorias
- Sugestão de treino baseado no desempenho dos scouts



Scout de Atletas



TREINO SCOUT









A IA JÁ CHEGOU NA SAÚDE

A pergunta é: o que nós vamos fazer com o tempo que ela vai nos devolver?

Tecnologia para ampliar a eficiência sem perder o humano



O QUE ESTAMOS REALMENTE DISCUTINDO?



A inteligência artificial não precisa substituir pessoas para transformar profissões.

ONDE A IA ENCONTRA A SAÚDE?



A IA pode estar antes, durante e depois do atendimento.

ISSO JÁ ESTÁ ACONTECENDO



A questão deixou de ser 'será que funciona?'. Agora precisamos perguntar 'onde, como e com quais limites devemos usar?'

Fontes: **FDA:** dispositivos médicos com IA, Artificial Intelligence-Enabled Medical Devices **Nature:** IA e descoberta/desenvolvimento de medicamentos, IA aplicada à mamografia.

QUANDO A IA ENTRA NO CONSULTÓRIO

SEM IA



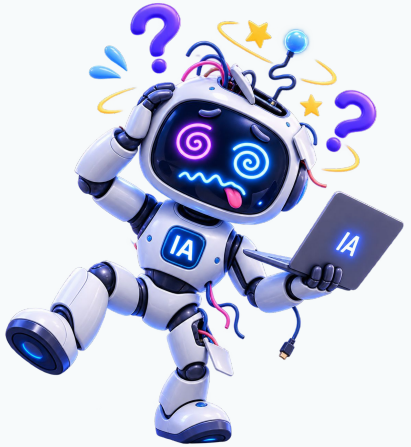
COM IA



Fonte: Estudos recentes sobre *ambient AI scribes* demonstram **redução de carga de documentação** e/ou **aumento do tempo de interação com o paciente**. *JAMA Network Open* / PubMed, 2025–2026.

LIMITES

IA ≠ VERDADE



DADOS → **PADRÕES** → **PROBABILIDADE** → **RESPOSTA**

Pode acertar.

Pode errar.

Pode reproduzir vieses.

Pode interpretar mal.

Uma IA pode produzir uma resposta convincente sem que essa resposta esteja correta.

Fonte: WHO — Ethics and governance of artificial intelligence for health

RESPONSABILIDADE

A regra de ouro

IA

ANALISA
ORGANIZA
SUGERE
ACELERA



→

PROFISSIONAL

INTERPRETA
CONTEXTUALIZA
DECIDE
ASSUME
RESPONSABILIDADE



A IA pode sugerir. Quem cuida precisa julgar.

REGULAÇÃO

Quem decide?



IA = apoio a decisão
Profissional = decisão final + responsabilidade profissional

Quanto maior o impacto da decisão, maior deve ser o nível de supervisão humana.

CFM / Resolução nº 2.454/2026 **(Níveis de risco)**

LGPD: dados referentes à saúde são dados pessoais sensíveis.

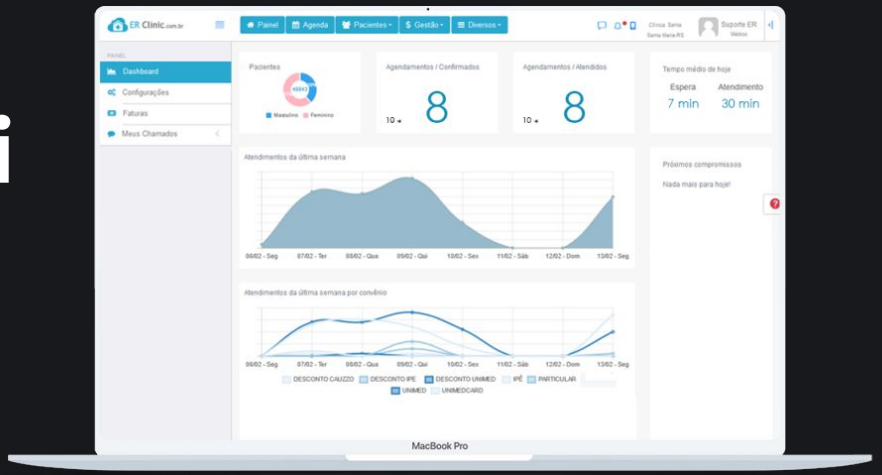
Fonte: CFM, Planalto / LGPD

Não é apenas abrir o Chat GPT! Tem norma: precisa ser auditável, parametrizável. Pronto para o crivo da comissão de IA.

ER Clinic.com.br

TRANSIÇÃO

E é exatamente aqui que entra a ERClinic



Como a IA pode potencializar o profissional?

Como colocar isso na rotina da clínica?

Conceito → potencial → limites → responsabilidade → prática

IA ao longo da jornada do paciente



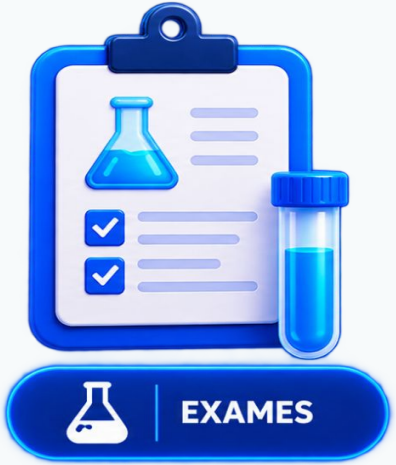
Chatbot para WhatsApp: **Atendimento 24h e agendamento automático**;

Alerta para paciente com alto **risco de não comparecimento** à consulta.



Ouve a consulta, **preenche automaticamente o prontuário**: Evolução, História da doença atual, Hipótese diagnóstica, Medicações e Plano de tratamento;

Resumo automático do **prontuário**.



A partir da **foto** ou **PDF** do **exame**. A **IA destaca** automaticamente **resultados fora dos padrões de referência**, organiza as informações e **gera um parecer final para apoiar a análise clínica**. Armazena no histórico do paciente, permite **acompanhar a evolução dos resultados por meio de gráficos**.



A partir da **base privada de conhecimento da clínica**, o **Córtex** localiza protocolos e conteúdos relevantes, organiza informações e sugere **condutas**, **exames** e **tratamentos com referências**. Um **copiloto exclusivo**, que amplia o conhecimento do profissional sem substituir sua **avaliação e decisão clínica**.

A IA deixa de ser uma ferramenta isolada e passa a fazer parte do fluxo da clínica.

ER Clinic.com.br

ERCLINIC / AGENDA ELETRÔNICA / FALANDO DE UMA MANEIRA MAIS TÉCNICA / CHATBOT AGENDAMENTO



1 - Chatbot para WhatsApp: Atendimento 24h e agendamento automático;

2 - Alerta para paciente com alto **risco de não comparecimento** à consulta.

ER Clinic.com.br

ERCLINIC / AGENDA ELETRÔNICA / FALANDO DE UMA MANEIRA MAIS TÉCNICA / CHATBOT AGENDAMENTO



Atualmente: recurso integrado com parceiro

Desejamos: desenvolver o nosso recurso próprio

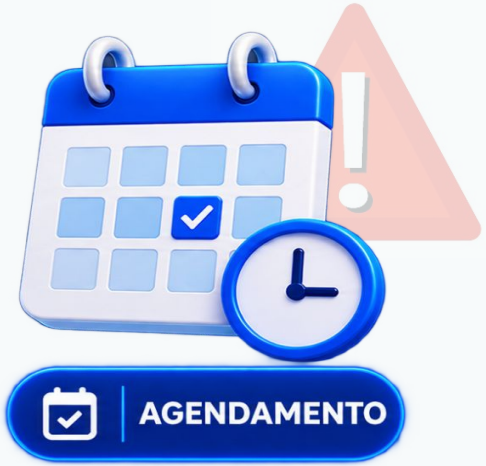
1 - Chatbot para WhatsApp: Atendimento 24h e agendamento automático

Fornecemos API para integração com terceiros:

- RAG (consulta nos endpoints da API)
- Prompt Engineering
- Processos N8N

ER Clinic.com.br

ERCLINIC / AGENDA ELETRÔNICA / FALANDO DE UMA MANEIRA MAIS TÉCNICA / ALERTA RISCO DE FALTA

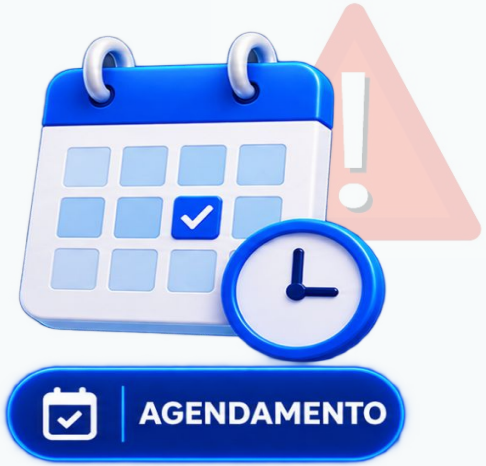


2 - Alerta para paciente com alto **risco de não comparecimento** à consulta.

- IA vai muito além das LLMs!
- Base com dados estruturados
- Machine Learning supervisionado

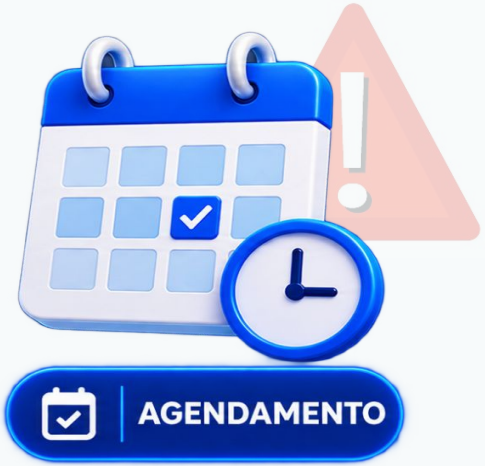
ER Clinic.com.br

ERCLINIC / AGENDA ELETRÔNICA / FALANDO DE UMA MANEIRA MAIS TÉCNICA / ALERTA RISCO DE FALTA



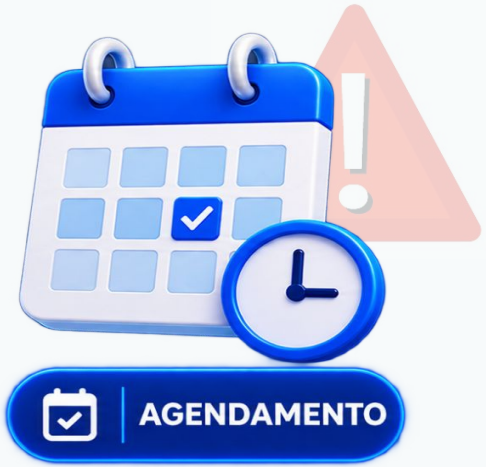
1. O que fazemos?

Utilizamos **Machine Learning supervisionado** para **estimar a probabilidade de um paciente não comparecer a uma consulta agendada**. O modelo aprende com **dados reais**, históricos e estruturados da própria plataforma ERClinic, utilizando exemplos de consultas em que o paciente compareceu ou faltou.



2. Técnica utilizada

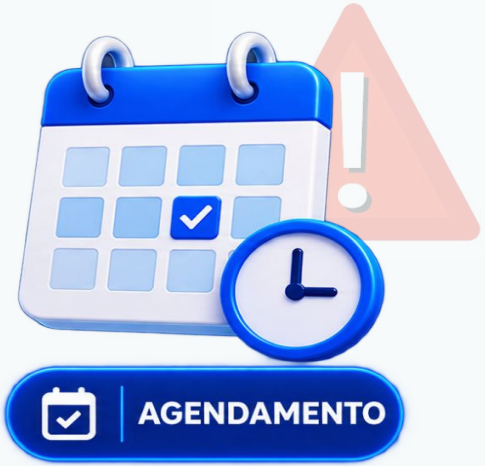
- **Algoritmo:** XGBoost, baseado em árvores de decisão combinadas (*gradient boosting*).
- **Tipo de problema:** classificação binária, com estimativa probabilística.
- **Treinamento supervisionado:** cada agendamento histórico é associado a um resultado conhecido: compareceu ou não compareceu.
- **Inferência:** quando um agendamento é criado, o modelo analisa suas características e retorna uma probabilidade de falta, que o sistema apresenta em faixas de risco.



3. A importância das variáveis

Uma etapa fundamental é selecionar as *features* adequadas. Atualmente, utilizamos nove variáveis, incluindo **histórico de faltas**, **taxa de faltas anteriores**, **resultado da última consulta**, **convênio**, **teleconsulta**, **agendamento online**, **dia da semana** e **horário da consulta**.

Essas **variáveis** permitem **identificar padrões estatísticos** que podem ajudar a **prever o comportamento futuro**. A escolha exige cuidado: **correlação não implica causalidade**. Se uma variável está associada a uma maior ocorrência de faltas, isso não significa que ela seja a causa. O modelo identifica padrões preditivos, não relações de causa e efeito.



4. Atualização e avaliação do modelo

Os **dados e os padrões de comportamento mudam com o tempo**. Por isso, executamos um **pipeline de treinamento que utiliza uma janela móvel dos últimos dois anos**, **treina um modelo candidato e compara seu desempenho com o modelo atual**.

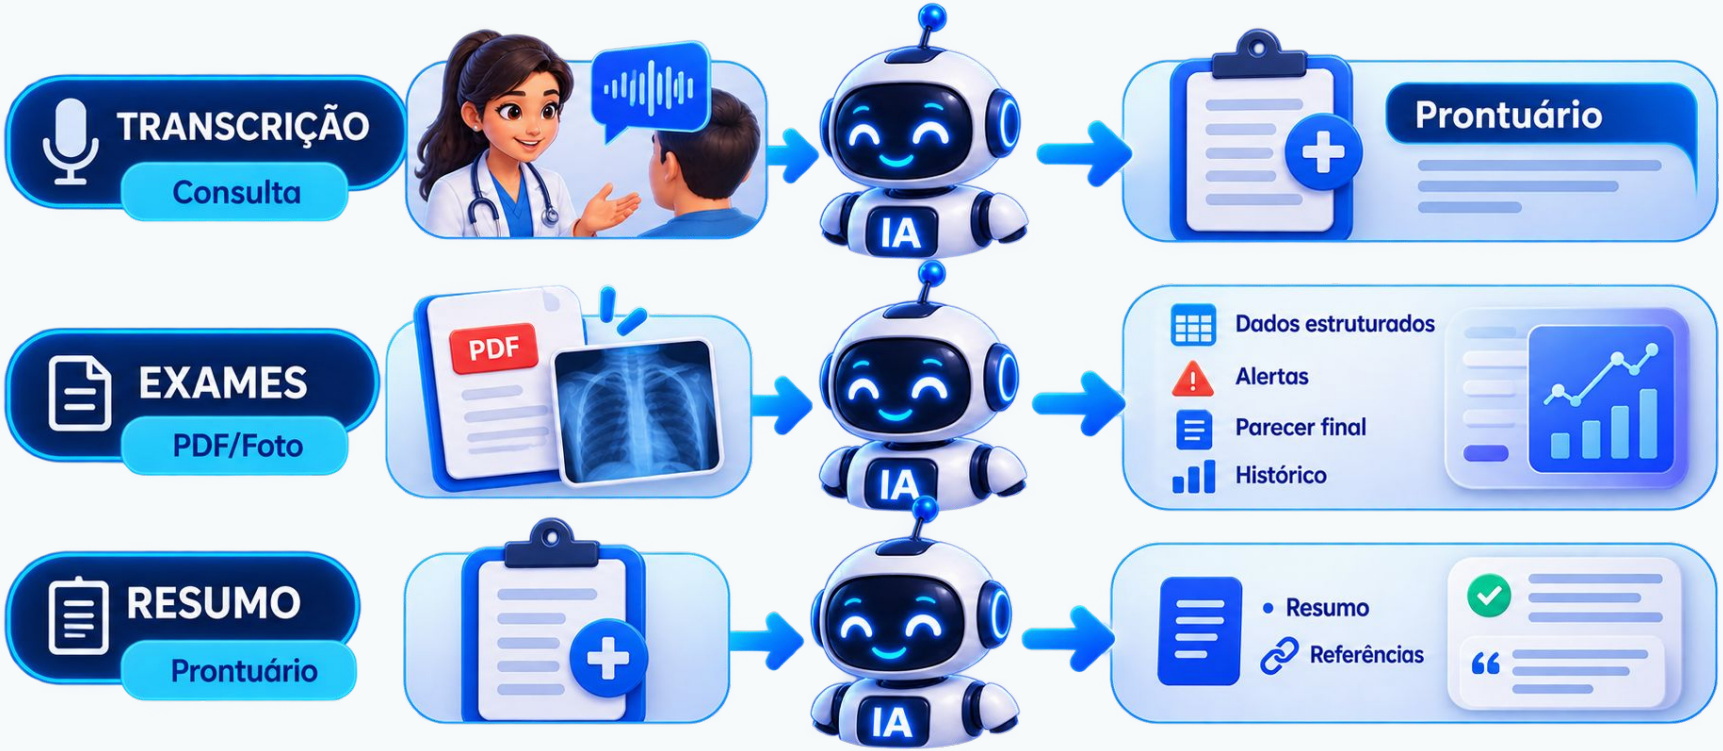
A **avaliação** considera **métricas** como **ROC AUC**, **Average Precision** e **Brier Score**, além da **relação entre as probabilidades previstas e as faltas efetivamente observadas**.

Uma nova versão é gerada, validada e versionada. Sua ativação depende de avaliação e decisão manual **(E-mail sugere ao staff ERClinic)**, permitindo evitar a substituição automática por um modelo que não demonstre melhoria suficiente.

ER Clinic.com.br

ERCLINIC / ASSISTENTE CLÍNICO / EXEMPLO PRÁTICO

Menos tempo registrando. Mais tempo atendendo.



ER Clinic.com.br



Inicialmente testamos criando uma camada de OCR desenvolvida localmente. Depois, identificamos que usando um modelo pago multimodal funciona melhor. Optamos então por modelos pagos via OpenRouter.

1. Tecnologias utilizadas

- **LLM multimodal via OpenRouter:** recebe os arquivos e interpreta seu conteúdo, extraindo informações estruturadas.
- **Processamento de arquivos:** PDFs são enviados como arquivos e imagens são enviadas como imagens, codificadas em Base64.
- **OCR:** o código também implementa PyMuPDF (fitz) para extração de texto de PDFs e Tesseract OCR para PDFs digitalizados e imagens, com suporte ao português.
- **Python + Django + Celery:** gerenciam o processamento assíncrono, o armazenamento e o acompanhamento do status da tarefa.



2. Fluxo do processo

1. **Entrada:** o profissional envia uma foto ou um PDF do exame.
2. **Preparação:** o sistema registra os arquivos e cria uma tarefa assíncrona, executada pelo Celery.
3. **Interpretação pela IA:** o modelo recebe o conteúdo do exame e instruções específicas para extrair os dados.
4. **Análise individual:** cada item é estruturado com descrição, valor, unidade, intervalo de referência e classificação: normal, alto, baixo ou crítico.
5. **Parecer geral:** além de classificar cada resultado, a IA produz um resumo clínico das alterações relevantes, sem substituir a avaliação profissional.
6. **Persistência:** o sistema registra os resultados no exame e no prontuário, permitindo consultar o histórico e acompanhar a evolução dos indicadores em gráficos.



3. Como a IA interpreta os documentos

O sistema combina instruções explícitas (*prompt engineering*) com a capacidade do modelo de interpretar documentos e imagens. O prompt define o formato esperado, os campos a extrair e as regras para classificar os resultados.

A resposta deve ser um **JSON estruturado**, que o sistema converte em registros individuais. Isso facilita a integração com o prontuário e a visualização dos resultados.



4. Camadas de cuidado (*guardrails*)

- **Preservação dos dados:** instruções para manter valores, unidades e referências originais e não inventar informações ausentes.
- **Contextualização:** o modelo recebe idade e sexo do paciente para considerar esses dados na interpretação.
- **Controle da resposta:** formato JSON obrigatório, estrutura padronizada e tratamento de respostas inválidas.
- **Confiabilidade operacional:** processamento assíncrono, controle de status, registro de erros e possibilidade de tentar outros modelos configurados.
- **Segurança clínica:** o prompt orienta a não inventar diagnósticos e deixa explícito que o parecer não substitui a avaliação médica.

ER Clinic.com.br



Inicialmente, testamos modelos de sumarização disponíveis na Hugging Face, mas nenhum apresentou resultados tão satisfatórios quanto os modelos comerciais. Por isso, optamos por utilizar modelos pagos, acessados por meio da OpenRouter, que ofereceram melhor desempenho na geração dos resumos clínicos.

1. Tecnologias utilizadas

- **LLM via OpenRouter:** geração do resumo usando modelos de linguagem configurados na aplicação.
- **Prompt Engineering:** instruções detalhadas para selecionar informações clinicamente relevantes, organizar o conteúdo por especialidade e gerar uma resposta estruturada.
- **Python + Django:** algoritmo que percorre os diferentes módulos e modelos de dados do prontuário.
- **JSON + renderização HTML:** a IA retorna seções, parágrafos, alertas e referências; o sistema transforma essa estrutura em um resumo navegável (Link de referência com o conteúdo na íntegra).



2. Fluxo do processo

1. **Coleta:** o algoritmo percorre diferentes registros: anamnese, evoluções, exames, prescrições, medicamentos, alergias, diagnósticos, documentos e outros módulos clínicos.
2. **Organização:** filtra os registros pertinentes ao paciente e ao profissional, organiza os atendimentos do mais recente para o mais antigo.
3. **Contextualização:** o histórico organizado é combinado com instruções específicas para a especialidade do profissional.
4. **Síntese pela LLM:** o modelo seleciona informações relevantes, elimina redundâncias e organiza o resumo em seções, priorizando informações recentes.
5. **Referências navegáveis:** cada informação pode apontar para a data do atendimento que lhe deu origem, permitindo acessar o registro original.
6. **Atualização incremental:** depois da geração inicial, o sistema envia o resumo existente junto aos dados do novo atendimento, atualizando somente o que for necessário, sem reconstruir todo o histórico a cada vez.





3. O principal desafio técnico

O prontuário não é uma única tabela de texto. É um conjunto de módulos, com estruturas e regras próprias. Foi necessário desenvolver um algoritmo que conhecesse essas estruturas e soubesse extrair os dados relevantes de cada uma, consolidando tudo em um histórico textual coerente antes de enviá-lo à LLM.





3. O principal desafio técnico

O prontuário não é uma única tabela de texto. É um conjunto de módulos, com estruturas e regras próprias. Foi necessário desenvolver um algoritmo que conhecesse essas estruturas e soubesse extrair os dados relevantes de cada uma, consolidando tudo em um histórico textual coerente antes de enviá-lo à LLM.



4. Camadas de cuidado (*guardrails*)

- **Relevância clínica:** o prompt considera a especialidade do profissional e prioriza informações úteis.
- **Controle temporal:** informações mais recentes têm prioridade sobre registros antigos equivalentes.
- **Redução de alucinações:** instruções explícitas proíbem inventar informações, criar diagnósticos ou sugerir tratamentos; dados sem sentido clínico devem ser descartados.
- **Rastreabilidade:** o resumo deve informar a origem e a data de cada informação. O sistema valida os links contra os atendimentos existentes e utiliza as datas registradas em sua própria base.
- **Renderização segura:** o HTML é gerado pelo sistema, com escape do texto retornado pela IA e elementos de formatação controlados.
- **Controle operacional:** o sistema registra o processamento, o modelo utilizado, a resposta original e eventuais erros, além de evitar o reprocessamento desnecessário do último atendimento já processado.



Atualmente: recurso integrado com parceiro

Desejamos: desenvolver o nosso recurso próprio

Tecnologias-chave: captura e transmissão de áudio em fragmentos, reconhecimento automático de fala (ASR/STT), LLM e Prompt Engineering para extração e organização das informações clínicas.

Principal motivação para evoluir: o custo da dependência de um fornecedor externo.

1. Como funciona atualmente — integração com parceiro

Fluxo técnico:

1. **Captura do áudio:** um widget de terceiros, integrado ao prontuário, grava a consulta e envia fragmentos de áudio ao servidor durante o atendimento.
2. **Reconhecimento de fala (Speech-to-Text):** ao finalizar a gravação, o servidor reúne os fragmentos e transcreve a conversa para texto.
3. **Contextualização clínica:** o texto é processado considerando a especialidade do profissional, desconsiderando conversas irrelevantes para o registro clínico.
4. **LLM + Prompt Engineering:** um modelo de linguagem organiza o conteúdo em um schema predefinido, preenchendo cinco campos:
    - Evolução;
    - História da doença atual;
    - Hipótese diagnóstica;
    - Medicações;
    - Plano de tratamento.
5. **Revisão profissional:** o conteúdo é inserido no prontuário e pode ser revisado, complementado ou editado pelo profissional.



2. O que desejamos desenvolver: solução própria

A ideia é construir nossa própria camada de processamento, controlando o fluxo desde a captura até o preenchimento do prontuário.

Fluxo previsto:

Áudio → Transcrição → Contextualização clínica → LLM → Dados estruturados → Prontuário.

- **Reconhecimento de fala:** escolher entre utilizar um serviço de transcrição via API ou hospedar um modelo próprio.
- **Base de conhecimento por especialidade:** utilizar técnicas de RAG (*Retrieval-Augmented Generation*) para recuperar informações relevantes de uma base especializada e fornecer contexto adicional à LLM.
- **Prompt Engineering:** definir regras para transformar a transcrição nos cinco campos clínicos, evitando inventar informações ou preencher lacunas sem evidência na conversa.





O desafio de arquitetura: onde fazer a transcrição?

Estamos avaliando duas abordagens:

A. Capturar o áudio e enviá-lo em fragmentos ao servidor. Permite controlar o pipeline de processamento, mas exige tratar compatibilidade entre dispositivos, formatos de áudio, conectividade, ordenação dos fragmentos e recuperação de falhas.

B. Transcrever no frontend e enviar somente o texto. Reduz o volume de dados transmitidos e simplifica o processamento no servidor, mas depende dos recursos de reconhecimento de fala disponíveis no navegador ou dispositivo, cuja compatibilidade e qualidade podem variar.

A decisão exige um protótipo comparativo, avaliando qualidade da transcrição em português, terminologia médica, latência, custo, compatibilidade e privacidade.

Sugestões / Contribuições?

ER Clinic.com.br

ERCLINIC / CÓRTEX / EXEMPLO PRÁTICO

Copiloto Clínico



INFORMAÇÃO DO PACIENTE → **CONHECIMENTO DA CLÍNICA** → **BUSCA ORGANIZAÇÃO SUGESTÃO** → **REFERÊNCIAS DECISÃO DO PROFISSIONAL**

Conhecimento que estava espalhado em protocolos passa a estar disponível no momento da decisão.

Ele é um copiloto. Quem continua no comando é o profissional.



1. O que é?

Uma arquitetura de copilotos clínicos configuráveis, cada um com seu próprio prompt, modelo de linguagem e base privada de conhecimento. A proposta é permitir que a IA consulte protocolos, diretrizes e documentos específicos para apoiar o profissional em determinada situação clínica.



2. Técnica principal: RAG (*Retrieval-Augmented Generation*)

Em vez de treinar novamente o modelo de linguagem com os documentos médicos, utilizamos esses documentos como contexto durante cada consulta.

Pipeline de conhecimento:

1. **Extração:** leitura do conteúdo dos documentos enviados.
2. **Chunking:** divisão do conteúdo em trechos menores, com sobreposição entre eles para preservar o contexto.
3. **Embeddings:** transformação dos trechos em **vetores numéricos** que representam características semânticas do conteúdo.
4. **Base vetorial:** armazenamento dos vetores no **Pinecone**.
5. **Recuperação: busca semântica** dos trechos relevantes para a pergunta.
6. **Reranking:** reclassificação dos resultados para selecionar os mais pertinentes.
7. **Geração:** a LLM recebe a pergunta, o prompt específico e o contexto recuperado e produz a resposta. *Prompt Engineering.*



3. Tecnologias utilizadas

- **LLM:** modelo de linguagem configurável por copiloto; a configuração documentada utiliza GPT-5 como exemplo mas também trabalhamos com Gemini Flash.
- **Embeddings:** OpenAI `text-embedding-3-small`.
- **Banco vetorial:** Pinecone, com busca por similaridade semântica.
- **Reranking: Cohere Rerank**, para refinar a seleção dos trechos recuperados.
- **Backend:** API REST em Django, com processamento assíncrono via Celery e Redis. Integra o serviço com a plataforma ERClinic via API.



4. Guardrails e rastreabilidade

- **Base privada por copiloto:** isolamento do conhecimento associado a cada configuração.
- **Respostas fundamentadas:** instruções para utilizar a base disponível e explicitar quando faltam informações, em vez de completar lacunas com conhecimento externo. *Prompt Engineering.*
- **Controle de conteúdo:** regras para evitar inventar medicamentos, doses, posologias, contraindicações, condutas ou referências.
- **Saída estruturada:** a resposta pode ser devolvida em JSON, com campos como resumo, condutas, exames, medicamentos, sinais de alerta e observações.
- **Rastreabilidade:** registro dos trechos recuperados, arquivos e, quando disponíveis, páginas de origem dos documentos.



5. Principal desafio

Não basta conectar uma LLM a um conjunto de PDFs. **Precisamos recuperar os trechos certos**, **fornecer contexto suficiente**, **evitar informações sem sustentação documental** e **avaliar se a resposta realmente corresponde às fontes consultadas**.

ER Clinic.com.br

O QUE VEM POR AÍ...

Cervix

Assistente de Laudos para Colposcopia

Imagem → IA identifica regiões de interesse

Profissional avalia → Laudo → Prontuário



ER Clinic.com.br

FECHAMENTO

O que queremos ganhar?

PROFISSIONAL	CLÍNICA	PACIENTE	CUIDADO
TEMPO	EFICIÊNCIA	ACESSO	HUMANIDADE

Tecnologia para devolver tempo ao humano.

IA para ampliar o cuidado, sem medo.

ER Clinic.com.br

FECHAMENTO

E para nós da computação?

Minha humilde contribuição. Leve esta frase:

“Na computação, não somos o fim, somos o meio. Dominar técnicas, ferramentas e boas práticas é essencial, mas é preciso ir além do código: conhecer o negócio, compreender as pessoas e se envolver com a área que queremos transformar. Porque a tecnologia, por si só, não transforma a sociedade. O que transforma é a capacidade de conectar conhecimento técnico às necessidades reais do mundo.”

ER Clinic.com.br

Obrigado!